LABORATUVAR 7 · GENEL SÜRÜM · Şişeleme Hattı

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Hassan Chawa | Grup Yazılım Müh. | Tarih 23 Ekim 2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Mevcut tasarımda OK kararı tek kanallıdır ve ikinci kontrol yoktur. Olması gereken: kritik OK kararları bağımsız ikinci kontrol (farklı sensör veya ölçüm) ile doğrulanır; uyuşmazlık veya kritik sınıfta insan onayı istenir. Kusurlu parça sonradan bulunursa parça kaydı ile geri izlenir ve örneklemeli denetim yapılır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Tespit: çözünürlük ve zaman damgası tutarsızlığı, donmuş/tekrarlayan kare, istatistiksel anomali, kamera sağlık kontrolü ve bağımsız sensörle (LiDAR veya ikinci kamera) çapraz kontrol. Şüpheli girdide YZ kararı kullanılmaz: parça RED edilir, robot güvenli duruma geçer, operatör bilgilendirilir ve olay loglanır; kamera kanalının bütünlüğü doğrulanır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşik, kalibrasyon verisi ve risk değerlendirmesiyle belirlenir; kritik kararlarda yüksek tutulur ve gerekçesi emniyet dosyasında belgelenir. Eşik altında sıralama: önce insana sorulur (robot güvenli şekilde bekler); insan yanıt vermezse dur (fail-safe) ve deterministik kural tabanlı fallback devreye girer.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Human override + ikinci kontrol: YZ OK verse bile bağımsız ikinci kontrol veya insan onayı kararı durdurur; belirsizlikte RED'e düşülür (fail-safe).
Girdi manipüle edildi	Monitoring + fallback: Çapraz sensör, zaman damgası ve istatistik tutarsızlığı algılanınca YZ kararı kullanılmaz, parça RED edilir ve insan uyarılır.
Confidence düştü	Confidence threshold + fallback: Eşik altında robot durur veya insana sorulur; yanıt yoksa deterministik kural tabanlı fallback devreye girer.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.